

기초 이론부터 실무 실습까지  
머신 러닝 익히기

# Part 02. 머신러닝 기초와 배경

정 정 민

## Chapter 05. 머신러닝에 필요한 선형대수

---

1. 기본 개념과 용어 정의
2. 행렬 연산과 성질
3. 고유벡터와 고유값
4. 특이값 분해
5. 주성분 분석

# 기본 개념과 용어 정리


# 선형대수??

---

- 수 들이 모여있는 개념과 관련된 식을 연구하는 수학의 한 분야로
  - 수가 모여 있다는 것은 **벡터** 혹은 **행렬**이라고 함 등
  - 뒷 장표에서 자세히 설명
- 수를 다루는 많은 학문(데이터, 공학, 과학적 분석 등)에서 **수의 연산을 빠르고 효과적으로 하기 위해 사용하는 도구**
- 수의 집합을 **기하학적인 형상으로 적용**하여 표현
  - 시각적이고 직관적으로 수의 값을 이해할 수 있음
  - 기하학적으로 의미를 갖는 다양한 변환을 수학적으로 정의할 수 있음 (회전, 스케일링 등)
- 컴퓨터 그래픽스, 엔지니어링, 물리학, 컴퓨터 과학, 머신러닝 등 다양한 분야에서 응용됨
- 특히 머신러닝에서는 데이터를 표현하고 변환하는데 필수적인 도구로 사용!

# 수의 집합 : 스칼라, 벡터, 행렬, 텐서

- 숫자는 **특정한 방향으로 줄을 서듯 모일 수 있음**
  - 방향을 보통 차원이라고 부르며
  - 숫자들이 얼마나 모이는지에 따라 크기가 정해짐
- **스칼라** : 다른 숫자와 함께하지 않고 홀로 존재하는 수
- **벡터** : 한쪽 방향(차원)으로만 숫자가 모인 형태 → 1차원
- **행렬** : 두 방향으로 숫자가 줄을 선 형태 → 2차원
- **텐서** : 벡터와 행렬을 일반화한 개념.
  - 0차원 텐서를 스칼라라고
  - 1차원 텐서를 벡터라고
  - 2차원 텐서를 행렬이라고 부르며
  - 3차원 이상의 수 집합을 나타내는 용어이기도 함



## 데이터를 벡터와 행렬로

---

- 한 친구 A의 정보가 다음과 같음
  - 출석 번호 : 3 / 혈액형 : O / MBTI : ENTP / 키 : 163 / 중간고사 평균 : 92 / 기말고사 평균 : 96
- 이 친구의 정보는 아래와 같이 벡터로 나타낼 수 있음
  - 숫자와 글자를 모두 받는다고 가정
  - [3, O, ENTP, 163, 92, 96]
  - 총 6의 크기를 갖는 vector로 변환 가능
- 여기서 이 친구 학급에 있는 모든 친구들의 정보를 다 이렇게 변환하면
  - [ [3, O, ENTP, 163, 92, 96],  
[4, A, INTP, 168, 89, 88],  
...  
[10, B, ESTJ, 155, 88, 82],  
[11, AB, ENFP, 170, 90, 91]]
- 이처럼 데이터를 벡터 혹은 행렬의 형태로 변환 가능

# 행렬 연산과 성질



## 행렬의 덧셈과 뺄셈

---

- 행렬도 수의 집합이므로 연산이 가능
  - **행렬** 뿐 아니라, **벡터** 그리고 나아가 **모든 종류의 텐서**에 적용 가능
- 행렬의 덧셈과 뺄셈은 **같은 크기의 행렬**끼리만 가능
- 각 행렬의 **같은 자리에 있는 원소끼리**의 덧셈과 뺄셈
  - 이렇게 같은 자리에 있는 원소끼리의 연산을 element-wise operation이라고 함
- $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} + \begin{bmatrix} 5 \\ 6 \end{bmatrix} = \text{연산 안됨}$
- $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} + \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 6 & 8 \\ 10 & 12 \end{bmatrix}$ 
  - Element-wise sum!

## 행렬의 곱셈

- 행렬의 곱셈은 일반적인 수의 곱과는 다름
- 행렬의 곱은 하나의 행렬의 각 행과 다른 행렬의 각 열 간의 내적을 의미함
  - 내적이란, 벡터 간의 연산을 의미함
  - 두 벡터의 동일한 위치에 있는 원소를 곱한 후, 그 결과를 모두 더하는 연산 (결과는 스칼라)
    - $a = [1\ 2\ 3] / b = [4\ 5\ 6]$
    - $a \cdot b = 1 \cdot 4 + 2 \cdot 5 + 3 \cdot 6 = 32$
- Element-wise 연산이 아니므로 행렬의 크기가 달라도 연산이 가능
- 대신, 앞선 행렬의 열과 뒤 행렬의 행의 크기가 같아야 함

$$m \begin{pmatrix} n \\ A \end{pmatrix} \times \begin{pmatrix} k \\ n \\ B \end{pmatrix} = m \begin{pmatrix} k \\ AB \end{pmatrix}$$

## 우리가 아는 수의 곱셈은 뭘까?

---

- 같은 크기의 행렬에서 각 요소 별로 곱하기하는 연산이 존재함
  - Element-wise multiplication
- 이를 Hadamard Product 라고 함
- 예를 들어
  - $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \circ \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} = \begin{bmatrix} 5 & 12 \\ 21 & 32 \end{bmatrix}$

## 전치 행렬 (Transpose)

---

- 하나의 행렬이 주어질 때, **행과 열을 바꾼 행렬**을 전치 행렬이라고 함
- $A$  행렬의 크기가  $m \times n$  이라면
- $A$  행렬의 전치 행렬은  $A^T$  으로 표기하고, 그것의 크기는  $n \times m$  이 됨
- 예를 들어
- $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$  의 전치 행렬은  $A^T = \begin{bmatrix} a & c \\ b & d \end{bmatrix}$
- 대각선 원소는 전치 과정에서 그대로 유지됨
- 만약  $A = A^T$  인 경우,  $A$  를 대칭 행렬이라고 함
- 또한, 곱셈의 경우 순서가 바뀜
- $(AB)^T = B^T A^T$


## 역행렬 (Inverse Matrix)

- 특정 행렬  $A$ 에 어떤 행렬  $B$ 를 곱해보니 결과가 항등 행렬  $I = \begin{bmatrix} 1 & \cdots & 0 \\ \vdots & 1 & \vdots \\ 0 & \cdots & 1 \end{bmatrix}$  이라면
- 여기서  $B$ 를  $A$ 의 역행렬이라고 함
- 모든 행렬이 역행렬을 갖는것은 아님
- $A$  행렬이 역행렬을 가지려면,  $A$ 는 반드시 가역(또는 비특이, non-singular) 해야 함
  - 이를 수학적으로 표현하면  $\det(A) \neq 0$  을 만족해야 함
  - 방정식을 비유적으로 생각하면  $ax = 1$  을 만족하는  $x$ 를 찾고자 한다면  $a \neq 0$  이 아니어야 함!
  - ‘가역적’이라는 표현은 원래 상태( $I$ )로 돌릴 수 있음을 의미함
- 아래와 같은 성질이 있음
  - $(A^{-1})^{-1} = A$
  - $(AB)^{-1} = B^{-1}A^{-1}$
  - $(A^T)^{-1} = (A^{-1})^T$

# 고유벡터와 고유값

# 선형 변환 (Linear Transformation)

- 어떤 벡터( $v$ )가 있다고 해볼까요?
- 이 벡터는 벡터 크기 만큼의 차원 공간에 존재
- 여기에 특정 행렬( $A$ )를 곱해서 새로운 벡터 ( $v'$ )을 만들었다고 가정
- $v$ 와  $v'$ 는  $A$  행렬에 의해 방향이 바뀜
- 예를 들어..
  - $v = [1 \quad 1]$  ,  $A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$  이라면  $Av = \begin{bmatrix} -1 \\ 1 \end{bmatrix} = v'$
- 즉,
  - 특정 벡터에 어떠한 행렬을 곱하면
  - 벡터의 방향 혹은 크기가 변경
  - 이렇듯 벡터의 방향과 크기의 변경을 **선형 변환**이라고 함




## 고유벡터(Eigenvector)와 고유값 (Eigenvalue)

- 이제는 관점을 좀 바꿔볼까요?
- 앞서서는 벡터( $v$ )를 기준으로 살펴봤는데, 이번에는 특정 행렬( $A$ )의 입장에서 봅시다.

- 행렬  $A$ 에는 다양한 벡터를 곱할 수 있음
- 그러다 보면 아래와 같은 특징을 갖는 벡터 존재할 수 있음

$$Av = \lambda v$$


- 여기서  $\lambda$  : 임의의 상수
- 이를 해석하면
  - $A$  행렬에 임의의 벡터  $v$ 를 곱하니, 그 결과가
  - 벡터  $v$ 의 크기를 상수  $\lambda$ 배 한 벡터와 같다!
- 그런 벡터  $v$ 를 고유벡터(Eigenvector)라고 하고
- 그런 상수  $\lambda$ 를 고유값(Eigenvalue)라고 함





## 원진 알았는데... 그걸 왜 & 어디에 쓰나요??

- 행렬  $A$ 의 고유벡터는 행렬  $A$ 의 값이 가장 많이 분산되는 방향을 나타냄
- 분산이 많이 된다는 것은 많은 정보력을 갖고 있다고 볼 수 있음
- 일반적으로 데이터를 불러오면 행렬의 형태를 갖게 됨
- 이 데이터를 담아온 행렬을  $A$ 라고 보면,
- 데이터가 담고 있는 여러 정보 중 가장 의미가 큰 방향이 고유 벡터가 됨!
- 해당 방향으로얼만큼 분산이 이루어졌는지
- 분산의 크기를 나타내는 정도가 고유값
- 이러한 고유벡터와 고유값은 복수개가 가능하며
- 고유값을 기준으로 나열된 고유벡터는 해석력이 큰 방향의 순서를 의미함
- 이 둘은 데이터를 이해하고 계산하는 과정에서 사용됨
  - 의미를 유지한 상태로 데이터를 전처리 하거나
  - 행렬 계산을 간소화 하는 과정에서 사용됨



# 특이값 분해

# 특이값 분해 (Singular Value Decomposition, SVD)

---

- 중학교 수학에서 소인수 분해 기억 하시나요?
  - $30 = 2 \times 3 \times 5$
  - 즉, 복잡한 수(30)를 그 수를 구성하는 기본적인 블록(소수 2,3,5)으로 분해
- 행렬에도 이와 비슷한 과정이 있음
  - 복잡한 행렬  $A$  ( $m \times n$ )을 더 간단한 세 가지 행렬( $U, \Sigma, V^T$ )로 분해
  - $A = U\Sigma V^T$ 
    - $U$ 의 열 벡터들은  $A$ 의 왼쪽 특이 벡터로  $AA^T$ 의 고유 벡터
    - $V$ 의 열 벡터들은  $A$ 의 오른쪽 특이 벡터로  $A^T A$ 의 고유 벡터
    - $\Sigma$ 의 대각선 위의 값들로  $A$ 의 특이값
      - 원래 행렬  $A$ 의 데이터가 가진 중요도를 의미
- 이런 과정을 특이값 분해(SVD)라고 함

## “고유벡터와 고유값” 그리고 SVD의 관계

- 둘 다 특정 행렬  $A$ 에서 정보를 뽑아내는 과정
- 하지만 고유벡터와 고유값 분석은 행렬  $A$ 가 정사각 행렬일 경우에 사용 가능
- 반면, SVD는 직사각 행렬  $A$ 에 대해 사용 가능
- 따라서 SVD가 조금 더 일반적인 경우를 나타내며
- 고유벡터와 고유값은 SVD의 스페셜 케이스로 보면 됨

	SVD	고유벡터와 고유값
$A (m \times n)$ 직사각 행렬	사용 가능	사용 불가
$A (m \times m)$ 정사각 행렬	사용 가능	사용 가능

## $AA^T$ 는 무슨 의미인가요??

---

- $A$  행렬의 크기가  $(m \times n)$  이라고 할 때,
- 정사각 행렬이 아니므로 바로 고유벡터와 고유값 분석을 할 수 없음
- 따라서 행렬  $A$ 에서 행과 열 방향으로 나눠 따로
- 행 사이의 관계를 따로 보고 열 사이의 관계를 따로 보고자 함
- $AA^T$ 는  $(m \times m)$  의 크기를 갖고 있어 고유벡터와 고유값 분석이 가능
- $AA^T$ 는 원래 행렬  $A$ 의 행 사이의 관계도가 데이터의 형태로 존재하며
- 그들의 정보력 중 분산이 크고 중요한 의미를 갖는 방향 벡터가  $U$  행렬 안에 정리될 것
- $A^T A$ 도 마찬가지
- 단 원본 행렬  $A$ 의 열 사이의 관계를 바탕으로 고유값 및 고유벡터 분석 진행

## 마지막 $\Sigma$

---

- $AA^T$  혹은  $A^T A$ 의 고유값의 제곱근 값을  $A$ 의 특이값이라고 함
  - $AA^T$ 의 고유값과  $A^T A$ 의 고유값은 서로 같음
- $\Sigma$  행렬은  $A$ 의 특이값을 대각선 위치에 갖고 있고
- 대각선을 제외한 나머지 모든 값은 0
- 고유값 분석과 마찬가지로
- 행렬  $A$ 의 선형 변환에서 중요한 스케일링 정보를 포함하고 있음

정리하면..  $m \times n$  크기를 갖는 행렬  $A$ 는

---

$$A = U\Sigma V^T$$

- $U$  (왼쪽 특이 벡터들)
  - 크기 :  $m \times m$
  - 원본 행렬  $A$ 의 행 정보를 바탕으로 중요도를 파악
- $V$  (오른쪽 특이 벡터들)
  - 크기 :  $n \times n$
  - 원본 행렬  $A$ 의 열 정보를 바탕으로 중요도를 파악
- $\Sigma$  (특이값들)
  - 크기 :  $m \times n$
  - 행렬  $A$  선형 변환 과정에서 영향을 미치는 스케일링 정보(특이값)를 포함

**E.O.D**